

# Class 1 线性回归

2018年10月19日 15:05

- 模型假设:

$$h_{\theta}(x) = \sum_{i=1}^m \theta_i x_i = \theta^T x$$


其中,  $\theta$  为参数,  $x$  为样本的特征,  $m$  为样本特征的维数。

- 损失函数: 最小均方误差 (LMS)

$$\begin{aligned} J(\theta) &= \frac{1}{2} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})^2 \\ &= \frac{1}{2} \sum_{i=1}^n (\theta^T x^{(i)} - y^{(i)})^2 \end{aligned}$$

其中,  $n$  为样本的个数。

- 优化目标:



$$\theta^* = \arg \theta \min J(\theta)$$

- 优化方法:

- 标准方程法

- 定义

$$X = \begin{bmatrix} -(x^{(1)})^T & - \\ -(x^{(2)})^T & - \\ \vdots & \\ -(x^{(n)})^T & - \end{bmatrix} \quad y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix}$$

其中，X 表示所有样本的特征集合，y 表示每个样本对应的真实值。

- 然后有，

$$X\theta - y = \begin{bmatrix} (x^{(1)})^T \theta \\ \vdots \\ (x^{(n)})^T \theta \end{bmatrix} - \begin{bmatrix} y^{(1)} \\ \vdots \\ y^{(n)} \end{bmatrix} = \begin{bmatrix} h_{\theta}(x^{(1)}) - y^{(1)} \\ \vdots \\ h_{\theta}(x^{(n)}) - y^{(n)} \end{bmatrix}$$

上式表示预测值与真实值之差的集合。

- 成本函数（最小二乘法）

$$J(\theta) = \frac{1}{2} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})^2 = \frac{1}{2} (X\theta - y)^T (X\theta - y)$$

- 通过矩阵微分计算梯度

$$\begin{aligned} \nabla_{\theta} J(\theta) &= \nabla_{\theta} \frac{1}{2} (X\theta - y)^T (X\theta - y) \\ &= \frac{1}{2} \nabla_{\theta} (\theta^T X^T X \theta - \theta^T X^T y - y^T X \theta + y^T y) \\ &= \frac{1}{2} \nabla_{\theta} \text{tr}(\theta^T X^T X \theta - \theta^T X^T y - y^T X \theta + y^T y) \\ &= \frac{1}{2} \nabla_{\theta} (\text{tr} \theta^T X^T X \theta - 2 \text{tr} y^T X \theta) = X^T X \theta - X^T y \end{aligned}$$

- 通过令梯度等于零求得闭式解

$$\theta^* = (X^T X)^{-1} X^T y$$

## ➤ 梯度下降法

- 简介：

- ❖ 梯度下降是求函数  $f(\theta)$  最小值的一阶迭代优化算法；
- ❖ 梯度下降方向是函数值增加最快的方向。

- 梯度：

$$\begin{aligned}
\frac{\partial J_l(\theta)}{\partial \theta} &= \frac{1}{2} \frac{\partial}{\partial \theta} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})^2 \\
&= \frac{1}{2} \cdot 2 \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot \frac{\partial}{\partial \theta} (h_{\theta}(x^{(i)}) - y^{(i)}) \\
&= \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)}) \frac{\partial}{\partial \theta} (\theta^T x^{(i)}) \\
&= \sum_{i=1}^n \boxed{(h_{\theta}(x^{(i)}) - y^{(i)}) x^{(i)}} \quad \text{"Error \cdot Feature"}
\end{aligned}$$

- 梯度下降优化:

$$\begin{aligned}
\theta &:= \theta - \alpha \frac{\partial}{\partial \theta} J_l(\theta) \\
&= \theta - \alpha \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)}) x^{(i)}
\end{aligned}$$